

CÔNG THỨC & LÝ THUYẾT ÔN GIỮA KỲ

Machine Learning cơ bản: Scaling - Linear Regression - Logistic Regression

Ghi nhớ: Bản này ưu tiên cách tính tay. Riêng RobustScaler của sklearn có cách tính Q1/Q3 khác cách chia nửa dưới/nửa trên.

A. Thống kê cơ bản

1. Mean - Trung bình

$$\text{Mean} = \bar{x} = (x_1 + x_2 + \dots + x_n) / n$$

- Mean = tổng các giá trị / số lượng giá trị.
- Mean không cần sắp xếp dữ liệu.

2. Median - Trung vị

- Bước đầu tiên: sắp xếp dữ liệu tăng dần.

$$\text{Nếu } n \text{ lẻ: Median} = x_{((n+1)/2)}$$

$$\text{Nếu } n \text{ chẵn: Median} = [x_{(n/2)} + x_{(n/2+1)}] / 2$$

- Ví dụ $n = 11$: 1,2,3,4,5,6,7,8,9,10,11 $\Rightarrow$ Median = $x_6 = 6$.
- Ví dụ $n = 12$: 1,2,3,4,5,6,7,8,9,10,11,12 $\Rightarrow$ Median = $(x_6 + x_7) / 2 = 6.5$.

3. Q1, Q3, IQR theo cách tính tay cơ bản

- Q1 = median của nửa dưới.
- Q3 = median của nửa trên.

$$\text{IQR} = Q3 - Q1$$

- Nếu n lẻ: bỏ median chính giữa, rồi chia nửa dưới/nửa trên.
- Nếu n chẵn: chia đôi trực tiếp, không bỏ số nào.

Ghi nhớ: Cách này hay dùng khi kiểm tra tay nếu đề không nói rõ sklearn/RobustScaler.

B. Scaling / Chuẩn hóa dữ liệu

1. Standard Scaling

$$x' = (x - \text{Mean}) / \text{Std}$$

$$\text{Std} = \sqrt{\sum((x_i - \text{Mean})^2) / n}$$

- Dùng Mean và độ lệch chuẩn Std.
- Dễ bị ảnh hưởng bởi outlier vì outlier kéo lệch Mean và Std.

Ví dụ Standard Scaling: 10, 20, 30

$$\text{Mean} = (10+20+30)/3 = 20$$

$$\text{Std} = \sqrt{((-10)^2 + 0^2 + 10^2) / 3} = \sqrt{200/3} \approx 8.16$$

$$10' = (10-20)/8.16 \approx -1.225$$

$$20' = (20-20)/8.16 = 0$$

$$30' = (30-20)/8.16 \approx 1.225$$

2. Min-Max Scaling

$$x' = (x - \text{Min}) / (\text{Max} - \text{Min})$$

- Dùng để đưa dữ liệu về khoảng 0 đến 1.

Ví dụ Min-Max Scaling: 10, 20, 30

$$\text{Min} = 10, \text{Max} = 30, \text{Max-Min} = 20$$

$$10' = (10-10)/(30-10) = 0$$

$$20' = (20-10)/(30-10) = 0.5$$

$$30' = (30-10)/(30-10) = 1$$

3. Robust Scaling

$$x' = (x - \text{Median}) / (Q3 - Q1) = (x - \text{Median}) / \text{IQR}$$

- Robust Scaling dùng Median và IQR.
- Ít bị ảnh hưởng bởi outlier hơn Standard Scaling.

Cách 1 - Tính tay cơ bản: Q1/Q3 là median nửa dưới/nửa trên

- Dữ liệu: 10, 20, 30. Median = 20. Vì n lẻ nên bỏ 20 ra.
- Nửa dưới = 10 => Q1 = 10. Nửa trên = 30 => Q3 = 30.

$$\text{IQR} = 30 - 10 = 20$$

$$10' = (10-20)/20 = -0.5$$

$$20' = 0$$

$$30' = (30-20)/20 = 0.5$$

Cách 2 - Tính tay giống RobustScaler của sklearn: percentile nội suy

$$\text{Vị trí } Q1 = 1 + (n-1)*0.25$$

$$\text{Vị trí } Q3 = 1 + (n-1)*0.75$$

- Với 10,20,30: n = 3.

$$\text{Vị trí } Q1 = 1 + 2*0.25 = 1.5 \Rightarrow Q1 \text{ nằm giữa 10 và 20} \Rightarrow Q1 = 15$$

$$\text{Vị trí } Q3 = 1 + 2*0.75 = 2.5 \Rightarrow Q3 \text{ nằm giữa 20 và 30} \Rightarrow Q3 = 25$$

$$\text{IQR} = 25 - 15 = 10$$

$$10' = (10-20)/10 = -1; 20' = 0; 30' = (30-20)/10 = 1$$

Ghi nhớ: Nếu đề thi ghi RobustScaler hoặc sklearn thì dùng cách percentile nội suy. Nếu đề chỉ bảo tính Q1/Q3 bằng tay cơ bản thì dùng median nửa dưới/nửa trên.

C. Chia dữ liệu

1. Train / Validation / Test

- Train set: dùng để huấn luyện mô hình.
- Validation set: dùng để chọn mô hình, chọn tham số, theo dõi trong quá trình train.
- Test set: dùng để đánh giá cuối cùng, không dùng để học.
- Ví dụ chia Train/Test = 80% / 20%.

2. K-fold Cross Validation

- Chia tập train thành K phần bằng nhau.
- Mỗi lần dùng K-1 phần để train, 1 phần để validation.
- Lặp K lần. Kết quả cuối cùng = trung bình K lần đánh giá.

Lần	Train	Validation
1	2,3,4,5	1
2	1,3,4,5	2
3	1,2,4,5	3
4	1,2,3,5	4
5	1,2,3,4	5

3. Data Leakage

- Data leakage là khi thông tin từ test set bị dùng trong quá trình train.
 - Điều này làm kết quả đánh giá bị sai lệch, mô hình nhìn như tốt hơn thực tế.
- Đúng khi scaling: fit_transform trên train, transform trên validation/test
- Sai: fit_transform trên cả train và test

D. Linear Regression - LR

1. Ý nghĩa

- Linear Regression dùng để dự đoán giá trị liên tục.
- Ví dụ: giá nhà, điểm số, doanh thu, cân nặng.

2. Công thức dự đoán

Một biến: $\hat{y} = w \cdot x + b$

Nhiều biến: $\hat{y} = w_1 \cdot x_1 + w_2 \cdot x_2 + \dots + w_n \cdot x_n + b$

- x: dữ liệu đầu vào; y: giá trị thật; $\hat{y}$: giá trị dự đoán; w: weight/trọng số; b: bias.

3. Error, RSS, MSE

error = $\hat{y} - y$

RSS = $\sum ((y_i - \hat{y}_i)^2)$

MSE = $(1/N) \cdot \sum ((\hat{y}_i - y_i)^2) = \text{RSS} / N$

- MSE/RSS càng nhỏ thì mô hình càng tốt trên dữ liệu đang xét.

E. Gradient Descent cho Linear Regression

1. Tính trên 1 dòng dữ liệu - SGD

$\hat{y} = w \cdot x + b$

error = $\hat{y} - y$

$dw = 2 \cdot \text{error} \cdot x$

$db = 2 \cdot \text{error}$

$w_{\text{new}} = w_{\text{old}} - \alpha \cdot dw$

$b_{\text{new}} = b_{\text{old}} - \alpha \cdot db$

2. Tính trên toàn bộ dataset N dòng - Batch GD

$dw = (2/N) \cdot \sum ((\hat{y}_i - y_i) \cdot x_i)$

$db = (2/N) \cdot \sum (\hat{y}_i - y_i)$

$w_{\text{new}} = w_{\text{old}} - \alpha \cdot dw$

$b_{\text{new}} = b_{\text{old}} - \alpha \cdot db$

3. Các bước tính 1 epoch Linear Regression

- B1. Chuẩn bị dữ liệu x, y.
- B2. Khởi tạo $w = 0$, $b = 0$ hoặc giá trị đề cho.
- B3. Tính $\hat{y} = w \cdot x + b$.
- B4. Tính error = $\hat{y} - y$.
- B5. Tính loss MSE nếu đề yêu cầu.
- B6. Tính dw, db.
- B7. Cập nhật w, b.
- B8. Lặp lại nhiều epoch đến khi loss giảm nhỏ.

4. Batch / SGD / Mini-batch

Loại	Cách cập nhật
Batch GD	Dùng toàn bộ dữ liệu để tính gradient rồi cập nhật w, b.
SGD	Dùng từng dòng dữ liệu để tính gradient rồi cập nhật w, b.
Mini-batch GD	Chia dữ liệu thành nhóm nhỏ, mỗi nhóm tính gradient và cập nhật một lần.

F. OLS - Ordinary Least Squares

1. Ý nghĩa

- OLS là phương pháp tìm w, b sao cho tổng bình phương sai số nhỏ nhất.
 $w^* = (A^T A)^{-1} A^T y$
- A: ma trận dữ liệu có thêm cột 1 cho bias; y: vector giá trị thật; w^* : vector trọng số tối ưu.

2. Nhược điểm OLS

- Không dùng được nếu $A^T A$ không khả nghịch.

- Tổng tính toán nếu dữ liệu lớn/nhiều chiều.
- Dễ overfitting vì tập trung giảm lỗi trên train.

G. Logistic Regression - LogR

1. Ý nghĩa

- Logistic Regression dùng cho bài toán phân loại, thường là phân loại nhị phân 0/1.
- Ví dụ: đậu/rớt, spam/không spam, bệnh/không bệnh.

2. Công thức dự đoán

$$z = w \cdot x + b$$

$$y_{\text{hat}} = \text{sigmoid}(z) = 1 / (1 + e^{(-z)})$$

- Sigmoid biến z thành xác suất trong khoảng 0 đến 1.
Nếu $y_{\text{hat}} \geq 0.5 \Rightarrow \text{class } 1$; nếu $y_{\text{hat}} < 0.5 \Rightarrow \text{class } 0$

3. Error, gradient, cập nhật

$$\text{error} = y_{\text{hat}} - y$$

$$dw = (1/N) * \sum((y_{\text{hat}_i} - y_i) * x_i)$$

$$db = (1/N) * \sum(y_{\text{hat}_i} - y_i)$$

$$w_{\text{new}} = w_{\text{old}} - \alpha * dw$$

$$b_{\text{new}} = b_{\text{old}} - \alpha * db$$

4. Loss Logistic Regression - Binary Cross Entropy

$$\text{Loss} = -(1/N) * \sum[y_i * \log(y_{\text{hat}_i}) + (1 - y_i) * \log(1 - y_{\text{hat}_i})]$$

- Loss càng nhỏ thì mô hình phân loại càng tốt.

5. Các bước tính 1 epoch Logistic Regression

- B1. Chuẩn bị dữ liệu x, y.
- B2. Khởi tạo $w = 0$, $b = 0$ hoặc giá trị đề cho.
- B3. Tính $z = w \cdot x + b$.
- B4. Tính $y_{\text{hat}} = \text{sigmoid}(z)$.
- B5. Tính $\text{error} = y_{\text{hat}} - y$.
- B6. Tính dw, db.
- B7. Cập nhật w, b.
- B8. Lặp lại nhiều epoch.
- B9. Dùng ngưỡng 0.5 để phân class.

H. So sánh Linear Regression và Logistic Regression

Nội dung	Linear Regression	Logistic Regression
Bài toán	Dự đoán số liên tục	Phân loại
Output	Số bất kỳ	Xác suất 0 đến 1
Công thức chính	$y_{\text{hat}} = w \cdot x + b$	$y_{\text{hat}} = \text{sigmoid}(w \cdot x + b)$
Loss	MSE	Binary Cross Entropy
Error	$y_{\text{hat}} - y$	$y_{\text{hat}} - y$
dw	$(2/N) \sum(\text{error} * x)$	$(1/N) \sum(\text{error} * x)$
db	$(2/N) \sum(\text{error})$	$(1/N) \sum(\text{error})$
Dự đoán class	Không có	Có ngưỡng 0.5

I. Metrics đánh giá

1. Regression metrics

$$\text{MAE} = (1/N) * \sum(|y_i - y_{\text{hat}_i}|)$$

$$\text{MSE} = (1/N) * \sum((y_i - y_{\text{hat}_i})^2)$$

$$\text{RMSE} = \sqrt{\text{MSE}}$$

- MAE: trung bình sai số tuyệt đối.
- MSE: trung bình bình phương sai số.

- RMSE: cùng đơn vị với y nên dễ hiểu hơn MSE.

2. Classification metrics

	Predict 1	Predict 0
Actual 1	TP	FN
Actual 0	FP	TN

$$\text{Accuracy} = (TP + TN) / (TP + TN + FP + FN)$$

$$\text{Precision} = TP / (TP + FP)$$

$$\text{Recall} = TP / (TP + FN)$$

$$F1 = 2 * \text{Precision} * \text{Recall} / (\text{Precision} + \text{Recall})$$

- TP: đoán 1, thật 1. TN: đoán 0, thật 0. FP: đoán 1, thật 0. FN: đoán 0, thật 1.

J. Câu lý thuyết dễ ra

Epoch là gì? Một epoch là một lần mô hình học qua toàn bộ tập dữ liệu train.

Learning rate là gì? Learning rate alpha là tốc độ cập nhật tham số w, b. Alpha quá lớn có thể làm loss không giảm; alpha quá nhỏ làm học chậm.

Vì sao cần nhiều epoch? Vì sau mỗi epoch, w và b được cập nhật để loss giảm dần.

Vì sao cần train/test split? Để huấn luyện trên train set và đánh giá khách quan trên test set.

Vì sao RobustScaler tốt khi có outlier? Vì RobustScaler dùng median và IQR, ít bị ảnh hưởng bởi giá trị ngoại lai hơn mean và standard deviation.

Linear Regression khác Logistic Regression thế nào? Linear Regression dự đoán giá trị liên tục; Logistic Regression dự đoán xác suất và dùng cho phân loại.

Gradient Descent dùng để làm gì? Dùng để cập nhật w và b sao cho loss giảm dần.

Batch GD là gì? Dùng toàn bộ dữ liệu train để tính gradient rồi mới cập nhật tham số.

SGD là gì? Cập nhật tham số sau từng dòng dữ liệu.

Mini-batch GD là gì? Chia dữ liệu thành các nhóm nhỏ, mỗi nhóm tính gradient và cập nhật tham số một lần.

K. Tóm tắt công thức cần thuộc gấp

Linear Regression

$$y_{\text{hat}} = w * x + b$$

$$\text{error} = y_{\text{hat}} - y$$

$$\text{MSE} = (1/N) \sum ((y_{\text{hat}} - y)^2)$$

$$dw = (2/N) \sum (\text{error} * x)$$

$$db = (2/N) \sum (\text{error})$$

$$w_{\text{new}} = w_{\text{old}} - \alpha * dw$$

$$b_{\text{new}} = b_{\text{old}} - \alpha * db$$

Logistic Regression

$$z = w * x + b$$

$$y_{\text{hat}} = 1 / (1 + e^{(-z)})$$

$$\text{error} = y_{\text{hat}} - y$$

$$dw = (1/N) \sum (\text{error} * x)$$

$$db = (1/N) \sum (\text{error})$$

$$w_{\text{new}} = w_{\text{old}} - \alpha * dw$$

$$b_{\text{new}} = b_{\text{old}} - \alpha * db$$

$$y_{\text{hat}} \geq 0.5 \Rightarrow \text{class 1}; y_{\text{hat}} < 0.5 \Rightarrow \text{class 0}$$

Scaling

$$\text{Standard: } x' = (x - \text{Mean}) / \text{Std}$$

Min-Max: $x' = (x - \text{Min}) / (\text{Max} - \text{Min})$

Robust: $x' = (x - \text{Median}) / \text{IQR}$

$\text{IQR} = Q3 - Q1$